

SYRINE SMATI

Élève ingénieure à l'INSAT — recherche un stage de fin d'études (PFE) en IA / Machine Learning

syrene.smati28@gmail.com | +216 51 054 359

linkedin.com/in/syrine-smati-a613702b4 | github.com/syrinesmati | syrinesmati-portfolio.vercel.app

FORMATION

Institut National des Sciences Appliquées et de Technologie (INSAT)

Cycle Ingénieur, filière Génie Logiciel

Sept. 2024 – Aujourd'hui

Diplôme prévu : 2027

Institut National des Sciences Appliquées et de Technologie (INSAT)

Cycle Préparatoire Mathématiques, Physique et Informatique

Sept. 2022 – Juin 2024

Lycée Les Pères Blancs

Baccalauréat Mathématiques, Mention Très Bien – 18,73/20

2022

1^{re} de la région Tunis 2

EXPÉRIENCES PROFESSIONNELLES

TechTroll – Stagiaire IA, Le Caire, Égypte

Juin 2026 – Aujourd'hui

- Conception d'un **pipeline d'extraction de documents en production** couvrant **8 types de documents financiers et réglementaires** pour **OSSUS.ai**, plateforme d'IA souveraine de conformité (GRC) destinée aux fintechs et aux entités soumises à la réglementation financière saoudienne, avec des stratégies de parsing et d'extraction propres à la structure de chaque document.
- Développement de composants de **raisonnement de conformité fondés sur LLM**, évaluant les preuves extraites au regard des contrôles **SAMA CSF** avec justification conforme/non conforme ; benchmark de 8 LLM sur 36 cas de test et sélection du modèle de production, portant le taux de réussite des prompts à **83 %**.
- Développement en cours d'un moteur de mutation de documents de politique traduisant les constats d'audit en corrections automatisées de mise en conformité, par ciblage indexé et plans d'opérations JSON structurés.

Welyne – Stagiaire IA, Ariana, Tunisie

Août 2025 – Sept. 2025

- Amélioration à **79 %** de la précision de prédiction de la longueur de bras par benchmark d'architectures MLP et CNN sur données biométriques (sexe, taille, poids) ; modèle déployé en production au sein de **WeeFizz**, le moteur de mensuration corporelle de Welyne qui reconstitue un profil morphologique complet pour la recommandation de taille dans la mode en ligne et l'habillement professionnel.

Yonnov'IA – Stagiaire IA, télétravail, Marseille, France

Juin 2025 – Août 2025

- Conception d'un moteur de recommandation hybride pour Odoo eCommerce associant filtrage collaboratif et filtrage par contenu, portant la couverture des recommandations à **+30 %** sur l'ensemble du catalogue.
- Validation sur un catalogue de plus de **1 000 produits** ; **déployé en production** et utilisé aujourd'hui par les clients Odoo.

PROJETS

Système de dialogue oral en arabe tunisien – ASR & LLM

Année universitaire 2025–2026

- Co-conception d'un système de dialogue oral de bout en bout pour l'arabe tunisien (derja) associant ASR, recherche RAG et un LLM adapté au dialecte, livré en MVP avec un frontend React et des backends FastAPI en streaming. Benchmark de 10 modèles ASR en zero-shot puis fine-tuning d'omniASR-LLM-3B sur 344 h de parole tunisienne, réduisant le WER de **53 %** (0,68 → 0,38). Sélection d'Aya-Expanse-8B à l'issue d'un benchmark de 5 modèles, puis adaptation par pré-entraînement continu QLoRA (85 millions de tokens) et fine-tuning supervisé (31 700 paires), atteignant **76 %** de précision au token ; publié sous le nom **TounsLM-8B** sur Hugging Face.

Classification de sons respiratoires – Audio Spectrogram Transformer

Année universitaire 2025–2026

- Reproduction et extension d'un pipeline **AST + SAM** publié, sur le benchmark **ICBHI 2017** (6 898 cycles respiratoires annotés, fort déséquilibre de classes) : prétraitement en spectrogrammes de Mel, padding cyclique et rééchantillonnage pondéré. Fine-tuning d'un **Audio Spectrogram Transformer de 86 M de paramètres** atteignant **71 % de sensibilité** à 61 % de spécificité, soit un gain sur les 68,3 % de l'article de référence à spécificité égale. Ablation d'**ASAM**, de l'Asymmetric Loss et du Mixup, avec diagnostic d'un exposant de focalisation trop agressif dégradant la sensibilité au profit de la spécificité.

Prédiction des prix de l'immobilier tunisien – Data Mining

Année universitaire 2025–2026

- Construction d'un pipeline de prédiction des prix sur **25 646 annonces** agrégées depuis Kaggle et collectées par scraping sur deux plateformes tunisiennes : récupération par regex de la surface, du nombre de pièces et du type de bien dans les descriptions libres, imputation des prix par classification ascendante hiérarchique (Ward) et harmonisation de plus de 300 variantes de noms de régions en 239 zones canoniques. Benchmark de **5 modèles de régression** (Ridge, RandomForest, GradientBoosting, **XGBoost**, **LightGBM**) dans un pipeline **Scikit-learn** suivi par **MLflow** ; RandomForest atteint **$R^2 = 0,88$** en location (MAE 498 TND) et 0,73 en vente.

COMPÉTENCES

ML/DL : PyTorch, TensorFlow, Scikit-learn, XGBoost, LightGBM, Hugging Face Transformers, OpenCV, YOLO

Systèmes LLM : prompt engineering, benchmark et évaluation de LLM, RAG, fine-tuning QLoRA

Big Data : Spark, Airflow, HDFS, HBase, Kafka

MLOps : Docker, MLflow

Fullstack : React, Next.js, NestJS, FastAPI, .NET

Bases de données : PostgreSQL, MySQL, MongoDB, Redis, Neo4j

Langages : Python, SQL, JavaScript/TypeScript, C#

Langues : Anglais (courant), Français (langue maternelle), Arabe (langue maternelle), Espagnol (notions)